

Walmart Store Sales Forecasting

Previsão de Vendas
2010 - 2012

registros

lojas

depart.

variáveis

421.570

45

81

25

Período: fevereiro/2010 - outubro/2012

Tecnologias: Python · Pandas · Plotly Dash · Matplotlib

Identificação do conjunto de dados

- Nome: Walmart Store Sales Forecasting
- Fonte: Kaggle — competição pública de previsão de vendas no varejo
- Endereço: kaggle.com/c/walmart-recruiting-store-sales-forecasting
- Cobertura temporal: fevereiro de 2010 a outubro de 2012 (143 semanas)
- Escopo geográfico: 45 lojas localizadas nos Estados Unidos

Justificativa da escolha

Volume e riqueza

421.570 registros semanais com variáveis de vendas, clima, promoções e indicadores macroeconômicos (CPI, desemprego).

Diversidade analítica

Permite explorar sazonalidade, impacto de feriados, desempenho por tipo de loja e efetividade de promoções por departamento.

Relevância prática

Dados reais de um dos maiores varejistas do mundo, com aplicabilidade direta em decisões estratégicas de negócio.

Os dados originais são compostos por três arquivos CSV distintos:

train.csv	421.570	5	Store, Dept, Date, Weekly_Sales, IsHoliday
features.csv	8.190	12	Temperature, Fuel_Price, Markdown1 a Markdown5, CPI, Unemployment
stores.csv	45	3	Store, Type (A/B/C), Size (área em pés quadrados)

Problemas identificados antes do tratamento

- Valores ausentes: Markdown1 a Markdown5 com alta proporção de NaN (semanas sem promoção)
- Inconsistências: valores negativos registrados nas colunas de desconto (erro de sistema)
- Tipo incorreto: coluna Date armazenada como texto (string), não como objeto de data
- Sem variáveis temporais: ausência de colunas derivadas de data (Ano, Mês, Trimestre)

Problemas encontrados e soluções aplicadas

Valores ausentes (NaN)

Markdown1-5 preenchidos com 0.
Ausência indica semana sem promoção.

Valores inconsistentes

Markdown negativos substituídos por 0.
Desconto negativo é erro de registro.

Tipo de dado incorreto

Coluna Date convertida para datetime
com `pd.to_datetime()`.

Registros duplicados

Duplicatas removidas via
`drop_duplicates()`.

Engenharia de atributos — 9 novas variáveis criadas

Temporais

Ano, Mês, Trimestre (Q1-Q4)

Feriados

Nome do Feriado (Natal, Ação de Graças, Super Bowl...)
Análise de Vendas Walmart · Grupo 6 · PUC

Sazonais

Estação do Ano (Inverno/Primavera/Verão/Outono)

Promoções

Total Markdown (soma Markdown1-5), Flag Tem Promoção


Clima

Faixa de Temperatura (Frio/Agradável/Quente)

Porte

Porte da Loja (Pequena/Média/Grande — percentis 33/66)

Três arquivos combinados via left join para formar o dataset final:



Dashboard 1 — Visão Geral (estático)

- Objetivo: panorama executivo com as principais métricas do período completo
- 4 KPIs em destaque: total vendido, média semanal, melhor loja e semanas com feriado
- Callout de insight fixo com análise do impacto de feriados nas vendas

1. Evolução mensal das vendas (gráfico de área)

2. Vendas médias por tipo de loja A, B e C (barras)

3. Feriados vs. semanas normais + linha de média (barras)

4. Top 10 lojas por receita acumulada (barras horizontais)

Dashboard 2 — Análise Interativa (reativa)

Painel lateral com 5 filtros reativos:

7 gráficos reativos

atualizados em
tempo real

Padrões identificados na análise exploratória — parte 1

Feriados geram aumento médio de ~7% nas vendas semanais

Semanas com feriados como Natal e Ação de Graças apresentam vendas sistematicamente acima da média. O efeito é mais pronunciado no Q4 (out-dez), quando a diferença em relação a semanas normais pode ultrapassar 12%.

Lojas do tipo A concentram ~70% da receita total

As 22 lojas do tipo A (maior porte físico) dominam aproximadamente 70% de toda a receita do período analisado. Lojas B e C, mais numerosas proporcionalmente, possuem volume individual muito menor, revelando forte heterogeneidade no portfólio.

Q4 é consistentemente o trimestre de maior volume em todos os anos

Os meses de outubro, novembro e dezembro concentram o pico de vendas nos três anos analisados (2010, 2011 e 2012), refletindo o comportamento sazonal típico do varejo americano com as compras de fim de ano e Black Friday.

Promoções (Markdowns) têm impacto relevante apenas em semanas com feriado

O Total_Markdown apresenta correlação positiva com vendas principalmente em semanas de feriado. Em semanas comuns, o efeito promocional é diluído por outros fatores como sazonalidade e tipo de loja, sem impacto claro no volume.

As 10 melhores lojas concentram cerca de 30% da receita total

A distribuição de vendas entre as 45 lojas é altamente assimétrica. As 10 lojas de maior receita acumulam ~30% de todo o faturamento, indicando que decisões sobre essas lojas têm peso desproporcional nos resultados.

Temperatura apresenta relação fraca com o volume agregado de vendas

A análise por Faixa de Temperatura (Frio/Agradável/Quente) não revelou correlação forte com as vendas no nível da loja. O efeito climático parece ser mediado pela sazonalidade e varia por categoria de produto dentro de cada departamento.

Entregas do projeto

O que foi alcançado

Pipeline reproduzível

Aquisição, integração, limpeza e engenharia de 9 novas variáveis documentadas em script único e reutilizável.

Dashboards interativos

Dois painéis em Python Dash com design acadêmico, filtros reativos e 11 visualizações cobrindo diferentes ângulos dos dados.

Insights de negócio

Seis achados sobre sazonalidade, concentração de receita, impacto de feriados e efetividade de promoções no varejo Walmart.

Boas práticas

Projeto organizado em pastas (data/, scripts/, reports/, assets/) com README, requirements.txt e controle de versão (Git).