

Walmart Store Sales Forecasting — Kaggle

Pipeline de dados, dashboards interativos e insights sobre o comportamento de vendas em 45 lojas norte-americanas no período fev/2010 - out/2012.

Grupo 6

Pontifícia Universidade Católica — PUC · 2025

registros	lojas	departamentos	variáveis
421.570	45	81	25

Tecnologias:

Python · Pandas · Plotly Dash · Matplotlib

Período analisado:

Fevereiro de 2010 a Outubro de 2012 (143 semanas)

1. Base de Dados Escolhida

1.1 Identificação do Conjunto de Dados

O conjunto de dados utilizado é o Walmart Store Sales Forecasting, disponibilizado publicamente na plataforma Kaggle como parte de uma competição de previsão de séries temporais. Os dados compreendem registros semanais de 45 lojas do Walmart nos Estados Unidos, cobrindo 143 semanas entre fevereiro de 2010 e outubro de 2012. A base é composta por três arquivos CSV complementares, descritos na tabela abaixo.

train.csv	421.570	5	Store, Dept, Date, Weekly_Sales, IsHoliday
features.csv	8.190	12	Temperature, Fuel_Price, Markdown1-5, CPI, Unemployment
stores.csv	45	3	Store, Type (A/B/C), Size (área em ft²)

1.2 Justificativa da Escolha

A escolha da base foi motivada por três critérios principais: volume, diversidade analítica e relevância prática do contexto.

- Volume e qualidade dos dados:**

Com 421.570 registros semanais e cobertura de três anos consecutivos, a base oferece densidade estatística suficiente para análises de tendência, sazonalidade e impacto de eventos externos, sem necessidade de interpolação ou enriquecimento externo.
- Diversidade de dimensões analíticas:**

A presença simultânea de variáveis de vendas, fatores climáticos (temperatura), indicadores macroeconômicos (CPI, desemprego, preço do combustível) e campanhas promocionais (Markdown1 a Markdown5) viabiliza análises multidimensionais e cruzamentos entre contexto econômico e comportamento de consumo.
- Relevância e aplicabilidade prática:**

Os dados provêm de contexto competitivo real — uma das maiores redes de varejo do mundo — com potencial direto de aplicação em decisões de gestão de estoque, planejamento de campanhas e alocação de recursos por departamento e tipo de loja.

1.3 Escopo Temporal e Geográfico

O recorte temporal (2010-2012) captura três ciclos sazonais completos, incluindo eventos relevantes como a recuperação pós-crise de 2008, períodos inflacionários e variações no preço do combustível. As 45 lojas estão distribuídas em diferentes regiões dos EUA, com três perfis distintos (tipos A, B e C) que diferem em porte e mix de produtos.

2. Caracterização dos Dados Originais

2.1 Estrutura dos Arquivos

Antes de qualquer transformação, o conjunto é composto por três entidades independentes. O arquivo de vendas (train.csv) é o arquivo central, contendo uma linha por combinação de loja, departamento e semana. Os outros dois fornecem atributos de contexto para enriquecimento do dataset principal.

train.csv	Loja × Dept × Semana	Weekly_Sales (R\$)	Numérico contínuo
features.csv	Loja × Semana	Temperature (°F)	Numérico + Binário
stores.csv	Por loja (45 linhas)	Type, Size	Categórico + Inteiro

2.2 Variável-Alvo e Cobertura

A variável-alvo é Weekly_Sales, que representa a receita semanal por departamento em cada loja, expressa em dólares americanos. Os valores variam de negativos (devoluções) a mais de US\$ 700.000 por semana para os maiores departamentos das lojas tipo A. O período cobre de 05/02/2010 a 26/10/2012, com 143 semanas de observações.

2.3 Problemas Identificados Antes do Tratamento

A inspeção inicial do dataset revelou cinco categorias de problemas que precisavam ser endereçados antes da análise exploratória:

- Valores ausentes (NaN): Markdown1 a Markdown5 com alta proporção de valores nulos
- Inconsistências numéricas: descontos negativos registrados nas colunas de Markdown
- Tipo de dado incorreto: coluna Date armazenada como string, não como datetime
- Ausência de variáveis temporais: sem Ano, Mês, Trimestre ou Estação derivados
- Feriados sem identificação: IsHoliday é binária, sem nome do evento correspondente

2.4 Distribuição das Vendas por Tipo de Loja

As lojas do tipo A (22 unidades, maior porte) concentram aproximadamente 70% de toda a receita do período. As 17 lojas do tipo B e as 6 do tipo C, embora mais numerosas em relação ao tipo C, possuem volume individual significativamente menor. Essa assimetria é um padrão estrutural relevante para a interpretação de qualquer análise agregada: médias simples tendem a subestimar o desempenho das lojas tipo A.

3. Preparação e Tratamento dos Dados

O tratamento dos dados foi implementado no script preparacao_dados.py em quatro etapas: correção de valores ausentes, eliminação de inconsistências, conversão de tipos e engenharia de novos atributos.

3.1 Tratamento de Valores Ausentes

Markdown1-5 tinham NaN em semanas sem promoção, preenchidos com 0 via fillna(0). Ausência de promoção equivale semanticamente a desconto zero.

3.2 Correção de Inconsistências Numéricas

Markdown negativos substituídos por zero via df.loc[df[col] < 0, col] = 0. Desconto negativo é erro de registro — semanticamente inválido.

3.3 Remoção de Duplicatas e Padronização

drop_duplicates() garantiu unicidade de cada combinação loja × departamento × semana. Date convertida de string para datetime com pd.to_datetime().

3.4 Padronização Semântica de Feriados

A coluna IsHoliday (True/False) foi enriquecida com o nome do evento pelo mês: Super Bowl (fev), Dia do Trabalho (set), Ação de Graças (nov), Natal (dez).

3.5 Engenharia de Atributos — 9 Novas Variáveis

A engenharia de atributos criou nove variáveis para viabilizar os filtros dos dashboards e enriquecer o poder analítico do dataset processado:

Ano	Inteiro	Extraído de Date com .dt.year
Mes	Inteiro	Extraído de Date com .dt.month
Trimestre	Categórico	Q1 a Q4 derivado do Mês: (Mes-1)//3 + 1
Estacao	Categórico	Inverno/Primavera/Verão/Outono por mês
Faixa_Temperatura	Categórico	Frio (<45°F), Agradável (45-75°F), Quente (>75°F)
Nome_Feriado	Categórico	Super Bowl, Dia do Trabalho, Ação de Graças, Natal
Total_Markdown	Numérico	Soma de Markdown1 + ... + Markdown5
Tem_Promocao	Booleano	True se Total_Markdown > 0
Porte_Loja	Categórico	Pequena/Média/Grande por percentis 33% e 66% do Size

4. Integração dos Dados

4.1 Estratégia de Integração

Os três arquivos CSV representam entidades relacionadas por chaves comuns, de forma análoga a tabelas em um banco de dados relacional. A estratégia adotada foi o left join em duas etapas sequenciais usando o método `pd.DataFrame.merge()` do Pandas, garantindo que todos os 421.570 registros de vendas de `train.csv` fossem preservados integralmente no dataset final.


4.2 Etapa 1 — Junção com Dados de Lojas

O arquivo `train.csv` foi combinado com `stores.csv` utilizando a coluna `Store` como chave de junção (left join). Como `stores.csv` contém apenas 45 linhas (uma por loja), o resultado é uma expansão lateral do dataset de vendas: as variáveis `Type` e `Size` são adicionadas a cada registro, resultando em 421.570 linhas × 7 colunas. Não há perda de registros nessa operação.

4.3 Etapa 2 — Junção com Dados de Contexto

O resultado da Etapa 1 foi combinado com `features.csv` usando uma chave composta de três colunas: `Store`, `Date` e `IsHoliday`. A chave tripla foi necessária porque `features.csv` possui uma linha por loja por semana, enquanto `train.csv` possui múltiplas linhas por semana (uma por departamento). Sem a chave composta, o merge geraria duplicatas. O resultado adiciona 9 variáveis de contexto: `Temperature`, `Fuel_Price`, `MarkDown1-5`, `CPI` e `Unemployment`.

Representação do processo:



5. Construção dos Dashboards

Os dashboards foram desenvolvidos em Python com o framework Plotly Dash, que permite criar aplicações web interativas sem JavaScript. A interface é definida inteiramente em Python, com gráficos criados via Plotly Express. Os dois painéis compartilham o mesmo arquivo `app.py` e são acessados por abas (`dcc.Tabs`).

5.1 Dashboard 1 — Visão Geral (Estático)

O primeiro dashboard é um painel executivo sem filtros dinâmicos, projetado para comunicar rapidamente os principais indicadores do período completo. A organização segue hierarquia de informação: métricas no topo, seguidas de análises progressivamente mais detalhadas. Inclui os seguintes elementos:

- 4 KPI cards: total vendido, média semanal por loja, melhor loja e semanas com feriado
- Callout de insight: destaque visual com análise do impacto médio de feriados nas vendas
- Gráfico 1: Evolução mensal das vendas (gráfico de área com marcadores trimestrais)
- Gráfico 2: Vendas médias por tipo de loja A, B e C (barras verticais)
- Gráfico 3: Comparativo feriados vs. semanas normais com linha de média geral
- Gráfico 4: Top 10 lojas por receita acumulada (barras horizontais ordenadas)

5.2 Dashboard 2 — Análise Interativa (Reativa)

O segundo painel permite segmentação dinâmica dos dados via sidebar fixa com cinco filtros reativos. Cada alteração de filtro aciona callbacks que atualizam todos os sete gráficos simultaneamente, sem recarregar a página. Os filtros disponíveis são:

- Ano: checklist com seleção múltipla (2010, 2011, 2012)
- Tipo de loja: checklist A / B / C
- Porte da loja: checklist Pequena / Média / Grande
- Faixa de temperatura: dropdown Frio / Agradável / Quente
- Estação do ano: dropdown Inverno / Primavera / Verão / Outono

5.3 Decisões de Design e Organização Visual

O sistema de design é baseado em uma paleta acadêmica com azul (`#1A56A0`) como cor de acento e branco como fundo. As fontes IBM Plex Sans (corpo) e IBM Plex Serif (título) conferem legibilidade e formalidade. A sidebar do Dashboard 2 usa `position: sticky` para permanecer visível durante a rolagem. Um template Plotly customizado (academico) foi registrado globalmente para garantir consistência visual entre todos os gráficos.

6. Resultados e Insights

A análise exploratória do dataset processado revelou seis padrões relevantes sobre o comportamento de vendas. Cada insight foi identificado por agrupamento, comparação de médias ou distribuição entre categorias.

Insight 1 — Feriados elevam as vendas em média 7% acima da média semanal

Semanas com feriados registrados (IsHoliday=True) apresentam vendas consistentemente superiores à média geral. O efeito é mais pronunciado no Q4 (out-dez), com Natal e Ação de Graças impulsionando picos que chegam a 12% acima da média. O Super Bowl (fev) apresenta impacto menor mas ainda positivo, especialmente em lojas próximas a grandes centros urbanos.

Insight 2 — Lojas tipo A concentram aproximadamente 70% da receita total

As 22 lojas classificadas como tipo A (maior porte físico, acima do percentil 66 de tamanho) dominam a receita do período. Lojas tipo B e C, apesar de somarem 23 unidades, contribuem com os 30% restantes. Essa concentração implica que qualquer análise de tendência agregada é fortemente influenciada pelo desempenho das lojas tipo A.

Insight 3 — Q4 é o trimestre de maior volume em todos os três anos

Os meses de outubro, novembro e dezembro concentram sistematicamente o pico de vendas nos anos 2010, 2011 e 2012, refletindo o comportamento sazonal do varejo norte-americano com Black Friday, Cyber Monday e compras natalinas. O Q1 (jan-mar) apresenta o menor volume, com queda acentuada imediatamente após o Natal.

Continuação — Insights 4, 5 e 6

Insight 4 — Promoções (Markdowns) têm impacto relevante apenas em semanas com feriado

A variável Total_Markdown apresenta correlação positiva com vendas principalmente em semanas de feriado, sugerindo que campanhas promocionais amplificam o efeito já existente do feriado, mas não geram demanda nova em semanas comuns. Em semanas normais, o volume de Markdown não se traduz em aumento proporcional de vendas no agregado.

Insight 5 — As 10 melhores lojas respondem por cerca de 30% da receita total

A distribuição de receita entre as 45 lojas é altamente assimétrica. As 10 lojas de maior faturamento acumulam aproximadamente 30% de toda a receita do período. Esse nível de concentração indica que estratégias voltadas especificamente para as lojas de maior volume têm potencial de impacto desproporcional sobre o resultado consolidado da rede.

Insight 6 — Temperatura apresenta relação fraca com o volume agregado de vendas

A análise por Faixa_Temperatura (Frio, Agradável, Quente) não revelou correlação forte com o volume de vendas no nível da loja. As medianas de vendas nas três faixas de temperatura são próximas, e as distribuições se sobrepõem amplamente. O efeito climático pode ser relevante em categorias específicas de produto (ex.: roupas de inverno, bebidas), mas se dilui quando a análise é feita no agregado de todos os departamentos.

Síntese dos Achados

Os seis insights revelam que o desempenho de vendas no Walmart é fortemente determinado por três eixos estruturais: sazonalidade (Q4 e feriados), heterogeneidade do portfólio (tipo e porte das lojas) e concentração de receita (top 10 lojas). Fatores externos como temperatura e promoções exercem influência secundária ou mediada pelos eixos primários. Esses achados sugerem que iniciativas de alta alavancagem devem priorizar as lojas tipo A no período Q4, com atenção especial ao planejamento de estoque para semanas de feriado.

. Conclusão

Este projeto demonstrou a viabilidade de construir um pipeline completo de análise de dados — da aquisição à visualização interativa — com ferramentas de código aberto em Python. O conjunto de dados Walmart Store Sales Forecasting mostrou-se adequado aos objetivos do projeto: volume suficiente para análise estatística, diversidade de variáveis para análises multidimensionais e relevância prática para insights aplicáveis a contextos reais de varejo.

Contribuições do Projeto

- Pipeline reproduzível de preparação e integração de dados em script único
- Dataset enriquecido com 9 novas variáveis de engenharia de atributos
- Dashboard 1: painel executivo com 4 KPIs e 4 visualizações estáticas
- Dashboard 2: painel interativo com 5 filtros reativos e 7 gráficos dinâmicos
- 6 insights documentados sobre sazonalidade, concentração e promoções

Limitações

O dataset cobre apenas 2010–2012, limitando a generalização para padrões mais recentes do varejo. A análise é feita no nível de loja e não de produto individual, o que impede insights sobre mix de categorias. As variáveis macroeconômicas (CPI, desemprego) apresentam baixa variação semanal, reduzindo seu poder explicativo em análises de curto prazo.

Possibilidades de Melhoria

- Aplicar modelos preditivos (ARIMA, Prophet, XGBoost) para previsão de vendas futuras
- Incorporar dados externos como índices de confiança do consumidor e eventos locais
- Análise por departamento para identificar categorias mais sensíveis a feriados
- Deploy do dashboard em plataforma web (Heroku, Render) para acesso remoto

Referências

- Kaggle. Walmart Store Sales Forecasting. kaggle.com/c/walmart-recruiting-store-sales-forecasting
- McKinney, W. (2022). Python for Data Analysis, 3rd ed. O'Reilly Media.
- Plotly Technologies. Dash Documentation. dash.plotly.com
- Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. Computing in Science & Engineering.